



"2024 – 30°ANIVERSARIO DE LA DISPOSICIÓN
TRANSITORIA PRIMERA DE LA CONSTITUCIÓN NACIONAL

Aprendizaje Automático
Parcial
Entrega Final

Tec. Ciencia de datos e Inteligencia Artificial.
Aprendizaje Automático
2 año, 1 cuatrimestre
Antonela Scotto



**CENTRO POLITÉCNICO SUPERIOR
MALVINAS ARGENTINAS**

Clasificación de Asteroides Potencialmente Peligrosos

El objetivo principal de este proyecto es aplicar técnicas de aprendizaje automático para abordar un problema de interés astronómico: desarrollar un modelo predictivo capaz de clasificar objetos astronómicos y, en particular, identificar Asteroides Potencialmente Peligrosos (PHA).

Para esta etapa final se aplicaron dos tipos de modelos supervisados de clasificación: K-Nearest Neighbors (KNN) y Árbol de Decisión, con el fin de comparar su rendimiento bajo diferentes condiciones de preprocesamiento y balanceo de clases.

En el conjunto original, la variable objetivo "PHA" estaba fuertemente desbalanceada, con 88.182 casos de "0" (no peligroso) y solo 109 de "1" (peligroso). Este desbalance provocaba que los modelos aprendieran a predecir casi siempre la clase mayoritaria, ignorando la minoritaria y reduciendo su capacidad para identificar correctamente los casos verdaderamente peligrosos.

Ante esta problemática, se investigaron y aplicaron distintas técnicas de balanceo de clases. Inicialmente se utilizó Random Oversampling, que consiste en duplicar aleatoriamente los registros de la clase minoritaria hasta igualar su cantidad con la de la clase mayoritaria. De esta forma, ambas clases quedan equilibradas (88.182 de cada una), lo que permite al modelo aprender patrones representativos de ambas categorías y mejorar la detección de los casos menos frecuentes. Además, se aplicó un escalado de variables numéricas mediante StandardScaler, asegurando que todas las variables tuvieran la misma escala. Este paso es especialmente relevante para modelos basados en distancias, como KNN, donde la magnitud de las variables influye directamente en el cálculo de similitudes.

Resultados con Random Oversampling

Modelo KNN (escalado y balanceado):

- Accuracy: 0.9982
- Precision clase 0: 0.9997
- Recall clase 1: 0.7234
- F1-score clase 1: 0.50

El modelo logra una alta precisión global, pero aún tiene dificultades para identificar correctamente la clase minoritaria. Aunque el recall mejoró respecto al modelo sin balancear, el F1-score indica que todavía existen errores al clasificar los casos positivos. Esto se debe a que KNN depende fuertemente de la distancia entre puntos, y la clase minoritaria sigue siendo escasa en el espacio de características, incluso tras el oversampling.

Modelo Árbol de Decisión (escalado y balanceado):

- Accuracy: 1.0000
- Precision clase 0: 1.0000
- Recall clase 1: 0.9787
- F1-score clase 1: 0.9892

El árbol de decisión presenta un rendimiento casi perfecto en el conjunto de prueba. El alto recall muestra que identifica correctamente casi todos los casos positivos sin sacrificar precisión. Sin embargo, esta exactitud total puede sugerir sobreajuste (overfitting), es decir, que el modelo se adaptó demasiado a los datos de entrenamiento balanceados.

Resultados con SMOTE (Synthetic Minority Over-sampling Technique)

Posteriormente se aplicó la técnica SMOTE, una alternativa más avanzada de balanceo que genera nuevas instancias sintéticas de la clase minoritaria en lugar de duplicarlas.

SMOTE crea muestras artificiales basadas en los vecinos más cercanos de cada punto minoritario, lo que genera un espacio de características más continuo y realista, evitando la duplicación exacta de registros. Esta técnica permitió mejorar el aprendizaje del modelo, especialmente para la clase 1 ("peligrosos"), sin distorsionar tanto la distribución original.

Modelo Árbol de Decisión (con SMOTE):

- Accuracy: 1.0000
- Recall clase 1: 0.9787
- F1-score clase 1: 0.9892

Modelo KNN (con SMOTE):

- Accuracy: 0.9978
- Recall clase 1: 0.9149
- F1-score clase 1: 0.5029

El árbol de decisión mantuvo un desempeño sobresaliente, confirmando su capacidad para capturar relaciones no lineales y patrones complejos en los datos balanceados.

Durante la búsqueda del mejor valor de k para el modelo KNN, el ciclo for indicó que el valor óptimo era $k = 1$, pero aunque esta configuración mostraba la mayor accuracy, el resultado podía indicar sobreajuste al conjunto de entrenamiento. Por esta razón se decidió utilizar el F1-score de la clase 1 (asteroides peligrosos) como métrica principal, ya que combina precisión y recall, proporcionando una visión más justa del rendimiento del modelo sobre la clase minoritaria.

El modelo KNN alcanzó un F1-score de 0.5029 y una accuracy global de 0.9978, lo que demuestra un equilibrio más realista entre ambas clases. Aun así, se observó que el modelo era sensible a la distribución de los datos, ya que con $k=1$ tendía a memorizar los ejemplos del entrenamiento y a incrementar los falsos positivos.

El balanceo de clases, tanto mediante oversampling como con SMOTE, fue determinante para que los modelos pudieran reconocer de forma más efectiva los asteroides potencialmente peligrosos.

el Árbol de Decisión logró un rendimiento superior. Después del balanceo de datos y el ajuste de parámetros, alcanzó una accuracy perfecta de 1.0, con un excelente equilibrio entre precisión y recall. En este modelo, la impureza Gini fue la métrica utilizada para decidir las divisiones del árbol. Cada nodo buscó la variable que redujera al máximo la impureza, generando subconjuntos cada vez más homogéneos. Incluso en nodos con gini igual a cero, el árbol continuó dividiendo si eso contribuía a consolidar la pureza de las hojas y mejorar la clasificación final.

La interpretación del árbol resultó especialmente útil, ya que permitió identificar las variables físicas y orbitales que influyeron en la decisión final, ofreciendo una visión clara y explicable del proceso de clasificación.

En conclusión, el Árbol de Decisión se consolidó como el modelo más efectivo y transparente para la clasificación de asteroides potencialmente peligrosos, demostrando un rendimiento sobresaliente y una interpretación directa de los factores que determinan el riesgo de impacto.